

**CEFET/RJ - CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA
CELSO SUCKOW DA FONSECA**

Detecção de Pontos de Mudança em Séries Temporais Usando Autoencoders

Anthony Viegas Heimlich

Gabriel Alves Giuliano

Prof. Orientador:

Eduardo Soares Ogasawara, D.Sc.

Janio de Souza Lima, M.Sc.

Rio de Janeiro

28-01-2026

**CEFET/RJ - CENTRO FEDERAL DE EDUCAÇÃO TECNOLÓGICA
CELSO SUCKOW DA FONSECA**

**Detecção de Pontos de Mudança em Séries
Temporais Usando Autoencoders**

Anthony Viegas Heimlich

Gabriel Alves Giuliano

Projeto final apresentado em cumprimento às
normas do Departamento de Educação
Superior do Centro Federal de Educação
Tecnológica Celso Suckow da Fonseca,
CEFET/RJ, como parte dos requisitos para
obtenção do título de Bacharel em Ciência da
Computação.

Prof. Orientador:
Eduardo Soares Ogasawara, D.Sc.
Janio de Souza Lima, M.Sc.

**Rio de Janeiro
28-01-2026**

Obtenha a ficha catalográfica junto à biblioteca.

Substitua o arquivo **ficha.pdf** pela versão obtida lá.

RESUMO

A detecção de pontos de mudança (*Change Point Detection (CPD)*) em séries temporais industriais enfrenta desafios críticos devido à não estacionariedade dos dados, fenômeno conhecido como *concept drift*. Este trabalho propõe uma abordagem híbrida e não supervisionada para a detecção de anomalias no contexto da indústria de óleo e gás, utilizando o erro de reconstrução de autoencoders. A metodologia integra um *Vanilla Autoencoder (AE)*, responsável pela modelagem de padrões não lineares, a um supervisor estatístico baseado no algoritmo *Cumulative Sum (CUSUM)* com a estratégia de cruzamento de limiares (*Cross-Threshold (Cross-T_c)*). O componente estatístico atua no controle da estabilidade, definindo dinamicamente os momentos de retreinamento do modelo (esquecimento e reaprendizado) para mitigar os efeitos da degradação natural do processo. A validação experimental foi conduzida utilizando dados reais do *3W Dataset (3W)*, com foco na detecção de anomalias e falhas operacionais características presentes na base de dados. Os resultados demonstram que a abordagem proposta, aliada à adaptação informada, supera métodos estatísticos tradicionais, como o *Generalized Likelihood Ratio (GLR)*, oferecendo maior robustez contra falsos positivos e oscilações de curto prazo em comparação ao *Generalized Likelihood Ratio (GLR)*.

Palavras-chaves: detecção de pontos de mudança; séries temporais; autoencoders; CUSUM; Cross-Threshold; concept drift

ABSTRACT

Change Point Detection (CPD) in industrial time series faces critical challenges due to data non-stationarity, a phenomenon known as concept drift. This work proposes a hybrid, unsupervised approach for anomaly detection in the oil and gas industry, utilizing the reconstruction error of autoencoders. The methodology integrates a *Vanilla Autoencoder (AE)*, responsible for modeling non-linear patterns, with a statistical supervisor based on the *Cumulative Sum (CUSUM)* algorithm employing the Cross-Threshold (*Cross-Threshold (Cross-T_c)*) strategy. The statistical component manages stability control, dynamically defining model retraining moments (forgetting and relearning) to mitigate the effects of natural process degradation. Experimental validation was conducted using real data from the *3W Dataset (3W)*, focusing on the detection of anomalies and characteristic operational faults present in the database. The results demonstrate that the proposed approach, combined with informed adaptation, outperforms traditional statistical methods, such as *Generalized Likelihood Ratio (GLR)*, offering greater robustness against false positives and short-term fluctuations compared to *GLR*.

Keywords: change point detection; time series; autoencoders; CUSUM; Cross-Threshold; concept drift.

Sumário

1	Introdução	1
1.1	Informações sobre uso de IA neste trabalho	4
2	Fundamentação teórica	5
2.1	Séries Temporais: Definição e Estrutura	5
2.2	Eventos em Séries Temporais	6
2.3	Detecção de Pontos de Mudança	6
2.4	Aprendizado de Máquina na Detecção de Pontos de Mudança	7
2.5	Autoencoders: Arquitetura e Objetivo	8
2.6	Taxonomia dos Autoencoders	9
2.7	CUSUM	11
2.8	GLR	12
2.9	Erro de Reconstrução em Autoencoders	13
2.10	<i>Drift</i> e Aprendizado Adaptativo	13
3	Trabalhos Relacionados	16
3.1	Objetivo da Revisão	17
3.2	Processo de Revisão	17
3.3	Panorama dos Métodos de Detecção de Ponto de Mudança	17
3.4	Análise Crítica e Lacunas na Literatura	18
3.5	Contribuições do Presente Trabalho	19
4	Método	23
5	Resultados	27
5.1	Métricas de Avaliação	27
5.2	Resultados Quantitativos	28
5.3	Análise Visual e Qualitativa	32
5.4	Ameaças à Validade	34
6	Conclusão	36
Referências		38

Lista de Figuras

FIGURA 1:	Estrutura de um autoencoder Vanilla, destacando a codificação e a reconstrução a partir do espaço latente.	9
FIGURA 2:	Diagrama de estados representando o conceito de Adaptação Informada, onde o retreinamento é acionado apenas sob demanda.	15
FIGURA 3:	Fluxo geral do método.	23
FIGURA 4:	Adaptação do método proposto (AE + <i>Cumulative Sum (CUSUM)</i>) a um evento de <i>concept drift</i> .	33
FIGURA 5:	Resposta do algoritmo <i>GLR</i> ao mesmo evento de <i>concept drift</i> .	34

Lista de Tabelas

TABELA 1:	Comparação entre diferentes tipos de Autoencoders	11
TABELA 2:	Parâmetros e resultados das estratégias de busca na base Scopus	20
TABELA 3:	Artigos analisados: detalhamento e métodos comparativos	21
TABELA 4:	Métricas de detecção discriminadas por sensor para o Poço 1 (Instância do Tipo 1, <i>3W Dataset (3W)/Unified Time Series Event Detection Repository (UniTED)</i>)	28
TABELA 5:	Métricas de detecção discriminadas por sensor para o Poço 2 (Instância do Tipo 1, <i>3W/UniTED</i>)	28
TABELA 6:	Distribuição dos erros de classificação discriminada por sensor para o Poço 1 (Instância do Tipo 1, <i>3W/UniTED</i>)	29
TABELA 7:	Distribuição dos erros de classificação discriminada por sensor para o Poço 2 (Instância do Tipo 1, <i>3W/UniTED</i>)	30
TABELA 8:	Métricas de detecção com tolerância (250 amostras) discriminadas por sensor para o Poço 1	30
TABELA 9:	Métricas de detecção com tolerância (250 amostras) discriminadas por sensor para o Poço 2	31
TABELA 10:	Distribuição dos erros de classificação com tolerância (250 amostras) para o Poço 1	31
TABELA 11:	Distribuição dos erros de classificação com tolerância (250 amostras) para o Poço 2	32

Acrônimos

3W	3W Dataset.
ABD	Autoencoder-Based Breakpoints Detection.
AE	Vanilla Autoencoder.
CAE	Convolutional Autoencoder.
CNN	Convolutional Neural Network.
CPD	Change Point Detection.
Cross- T_c	Cross-Threshold.
CUSUM	Cumulative Sum.
DAE	Denoising Autoencoder.
GLR	Generalized Likelihood Ratio.
MC-TIRE	Multichannel Temporal Inception Recurrent Encoder.
RNN	Recurrent Neural Network.
SAE	Stacked Autoencoder.
TIRE	Time-Invariant Representation.
TSS	Time Series Segmentation.
UniTED	Unified Time Series Event Detection Repository.
VAE	Variational Autoencoder.

Capítulo 1

Introdução

Aprender padrões em séries temporais permanece um desafio relevante, especialmente em aplicações críticas como monitoramento de processos químicos, controle de qualidade industrial e vigilância ambiental [De Ryck et al., 2021]. Com o avanço de sensores e dispositivos conectados, cresce a demanda por métodos capazes de identificar transições abruptas no comportamento dos dados, indicando mudanças operacionais relevantes ou falhas iminentes [Gupta et al., 2022].

Dentre os conjuntos de dados utilizados na literatura para validar técnicas de detecção de pontos de mudança, destaca-se o *3W Dataset (3W)*¹, o primeiro conjunto de dados realista e público com eventos indesejáveis raros em poços de petróleo [Vargas et al., 2019]. Esses dados representam uma oportunidade concreta de aplicar métodos de detecção não supervisionada em sinais reais, nos quais as mudanças podem refletir falhas, transições operacionais ou eventos críticos [Cao et al., 2024; Liu et al., 2025].

Diferentemente da detecção de anomalias pontuais, que identifica valores isolados fora do padrão [Berahmand et al., 2024], a detecção de pontos de mudança foca a identificação de transições estruturais nos dados [Cao et al., 2024], como variações na média, na variância ou na dinâmica temporal [Gupta et al., 2022]. A detecção de pontos de mudança é considerada um problema não supervisionado, pois busca identificar esses pontos de transição sem conhecimento prévio de suas localizações [De Ryck et al., 2021]. Essas mudanças são particularmente relevantes em séries provenientes de sistemas físicos complexos, como os do *3W*, nas quais alterações nos sinais podem refletir a troca de estado de equipamentos, o início de falhas ou mudanças de regime de operação.

Um aspecto fundamental nesses cenários é a presença de não estacionariedade, isto é, a característica de processos cujas propriedades estatísticas, como média e variância, variam ao longo do tempo, manifestada pelo fenômeno conhecido como *concept drift* ou deriva de conceito. O *concept drift* ocorre quando o padrão de comportamento aprendido pelo modelo se altera, tornando o conhecimento anterior obsoleto [Liu et al., 2025; Gupta et al., 2022]. É im-

¹Disponível em : https://github.com/ricardovvargas/3w_dataset

portante ressaltar que o *drift* não constitui uma falha do sistema, mas sim uma evolução natural do comportamento da série temporal, decorrente da degradação física esperada de equipamentos ou de ajustes operacionais legítimos ao longo de processos de longa duração [Vargas et al., 2019; Liu et al., 2025]. O desafio computacional surge quando modelos de detecção estáticos, incapazes de acompanhar essa dinâmica, interpretam erroneamente a variação natural do processo como anomalias estruturais, resultando em altas taxas de falsos positivos [De Ryck et al., 2021; Liu et al., 2025]. Portanto, a estratégia de detecção deve ser capaz de distinguir entre a evolução natural do processo e as mudanças abruptas que exigem intervenção [Gupta et al., 2022].

Apesar de a aplicação de autoencoders ser mais recorrente na detecção de anomalias pontuais, esses modelos também podem ser utilizados na identificação de mudanças estruturais [De Ryck et al., 2021; Cao et al., 2024]. Em tarefas não supervisionadas, um autoencoder é treinado para reconstruir padrões normais dos dados. Assim, desvios persistentes no erro de reconstrução ao longo do tempo podem indicar alterações significativas no regime da série, sugerindo a ocorrência de pontos de mudança [Gupta et al., 2022].

Entre os métodos estatísticos tradicionais para *Change Point Detection (CPD)* destacam-se o *Cumulative Sum (CUSUM)* e o *Generalized Likelihood Ratio (GLR)*. O *CUSUM* acumula desvios em relação a uma média de referência e realça pequenas mudanças persistentes ao longo do tempo [Ygorra et al., 2024, 2021], enquanto o *GLR* identifica pontos de mudança ao comparar a verossimilhança de diferentes segmentos da série [De Ryck et al., 2021]. Ambos são métodos consolidados, mas assumem distribuições paramétricas dos dados e podem perder eficiência em cenários complexos [De Ryck et al., 2021].

Além disso, a robustez do *CUSUM* pode ser aprimorada por meio da estratégia de cruzamento de limiares, formalizada na literatura recente como *Cross-Threshold (Cross- T_c)* [Ygorra et al., 2024]. Essa abordagem propõe a combinação de resultados obtidos com diferentes níveis de sensibilidade, utilizando detecções de alta confiança para validar estatisticamente as detecções mais sutis [Ygorra et al., 2021]. O uso combinado desses limiares filtra falsos positivos causados por oscilações locais e ruídos de curto prazo, ao mesmo tempo em que preserva a capacidade de identificar a extensão completa dos desvios associados a mudanças de regime [Ygorra et al., 2021].

Nesse contexto, os autoencoders surgem como uma alternativa promissora devido à sua capacidade de aprender representações latentes de dados complexos, mesmo sem supervisão

[Berahmand et al., 2024]. Arquiteturas como autoencoders *Recurrent Neural Network (RNN)* e *Convolutional Neural Network (CNN)* capturam dependências temporais e estruturas internas de dados multivariados [Yoo et al., 2021; De Ryck et al., 2021; Cao et al., 2024], como os encontrados nos sinais elétricos do 3W.

A escolha pelos autoencoders justifica-se por suas propriedades intrínsecas, que os tornam adequados para tarefas de detecção de mudanças em séries temporais [De Ryck et al., 2021]. Diferentemente de modelos supervisionados, esses modelos não requerem dados rotulados [Berahmand et al., 2024], o que é relevante em cenários industriais, nos quais a anotação de falhas ou eventos de mudança é escassa ou inexistente. Além disso, sua capacidade de capturar representações latentes compactas permite generalizar o comportamento normal da série [De Ryck et al., 2021], tornando o modelo sensível a desvios estruturais, refletidos por aumentos significativos no erro de reconstrução [De Ryck et al., 2021; Gupta et al., 2022]. Essa sensibilidade é útil para identificar mudanças sutis que podem não ser detectadas por métodos estatísticos tradicionais ou que exigem suposições fortes sobre a distribuição dos dados [Li et al., 2024; De Ryck et al., 2021]. Arquiteturas como autoencoders *Recurrent Neural Network (RNN)* e *Convolutional Neural Network (CNN)* oferecem ainda a vantagem de capturar dependências temporais e padrões locais complexos [Yoo et al., 2021], reforçando sua aplicabilidade a séries temporais multivariadas e não lineares, com ruídos operacionais comuns em ambientes industriais [Cao et al., 2024].

Este trabalho tem como objetivo geral avaliar se a combinação de autoencoders com o *CUSUM* pode ser utilizada como critério eficaz para a detecção de pontos de mudança em séries temporais [De Ryck et al., 2021; Ygorra et al., 2024]. Assume-se a hipótese de que o erro de reconstrução acumulado pelo *CUSUM*, quando validado por meio da estratégia de cruzamento de limiares *Cross-Threshold (Cross-T_c)*, permite distinguir com maior precisão transições estruturais reais [Ygorra et al., 2024, 2021], resultando em uma detecção mais robusta frente a ruídos e oscilações locais [Ygorra et al., 2024; Li et al., 2024].

Especificamente, busca-se implementar e avaliar a aplicação de um autoencoder convencional (*Vanilla Autoencoder (AE)*), presente na biblioteca *daltoolbox*, aplicando o *CUSUM* com a estratégia *Cross-T_c* ao erro de reconstrução para identificar pontos de mudança [De Ryck et al., 2021; Ygorra et al., 2021; Li et al., 2024]. Além disso, pretende-se comparar o desempenho do método proposto com o *GLR* e discutir suas vantagens, limitações e aplicabilidade prática.

Embora a literatura recente, notadamente De Ryck et al. [2021], aponte que *Vanilla Au-*

toencoder (*AE*) podem apresentar limitações na captura de sutilezas espectrais ou correlações temporais complexas, sugerindo arquiteturas especializadas como redes recorrentes ou representações invariantes no tempo [Cao et al., 2024; Yoo et al., 2021], este trabalho opta deliberadamente pela arquitetura clássica. Essa escolha metodológica isola a variável de teste e demonstra que a robustez do sistema pode ser assegurada pelo supervisor estatístico (*CUSUM* com *Cross-T_c*), compensando a simplicidade da rede neural e validando uma abordagem computacionalmente eficiente para falhas de patamar típicas do conjunto de dados *3W*.

Este trabalho consiste em cinco capítulos além deste, fundamentação teórica onde serão apresentados conceitos fundamentais para o desenvolvimento do trabalho. Trabalhos relacionados, onde apresentaremos a revisão feita, analisaremos as lacunas na literatura e apontaremos as contribuições do presente trabalho. Método, onde será mostrado o que foi feito para elaboração do trabalho. Resultados, onde os resultados obtidos por meio dos métodos serão apresentados e discutidos. E por fim a conclusão onde analisaremos se os objetivos específicos do trabalho foram alcançados.

1.1 Informações sobre uso de IA neste trabalho

Este trabalho contou com o auxílio de recursos de inteligência artificial apenas para fins de ajuste de linguagem, reescrita de trechos específicos e organização do texto. O conteúdo técnico, as decisões metodológicas e os resultados obtidos permanecem como produção original do autor. Toda e qualquer contribuição sugerida pela inteligência artificial foi revisada e editada integralmente pelo discente para garantir a precisão e a autoria do documento.

Capítulo 2

Fundamentação teórica

Esta seção tem como objetivo apresentar os conceitos fundamentais que sustentam o desenvolvimento deste trabalho. Inicialmente, são discutidas as características das séries temporais e os principais tipos de eventos que podem ocorrer nesse tipo de dado. Em seguida, são explorados os conceitos relacionados à detecção de pontos de mudança *Change Point Detection (CPD)*, com ênfase em abordagens baseadas em aprendizado de máquina. Por fim, são detalhadas as arquiteturas de *AE*, as estratégias de regularização utilizadas e as métricas derivadas do erro de reconstrução, que constituem a base metodológica da proposta apresentada neste estudo [Li et al., 2024; Berahmand et al., 2024].

2.1 Séries Temporais: Definição e Estrutura

Séries temporais são sequências de observações coletadas ordenadamente ao longo do tempo. No contexto específico deste trabalho, o foco recai sobre séries temporais numéricas e contínuas, geradas pelo monitoramento de sensores industriais (como pressão, temperatura e vazão), coletadas em intervalos regulares (segundos ou minutos). Essa delimitação é fundamental para distinguir o objeto de estudo de outras formas de dados sequenciais, como sequências discretas de DNA, texto ou fluxos de vídeo, que demandam abordagens de modelagem distintas [Li et al., 2024]. Formalmente, a série temporal de interesse é representada como uma sequência ordenada $X = \{x_1, x_2, \dots, x_T\}$, onde cada $x_t \in \mathbb{R}^d$ é um vetor de leituras de sensores no instante t , caracterizando um sistema multivariado [Berahmand et al., 2024].

O principal desafio na análise de séries temporais está em modelar suas dependências temporais e identificar padrões subjacentes que possam indicar comportamentos anômalos ou mudanças estruturais. Tais padrões podem incluir tendências de longo prazo, variações sazonais, ciclos repetitivos ou alterações abruptas. Capturar essas estruturas é essencial para antecipar eventos críticos ou adaptar sistemas de controle em tempo real. A natureza sequencial dos dados exige, portanto, métodos capazes de explorar as relações entre observações ao longo do tempo, indo além de técnicas que tratam os dados de forma independente e estática [Li et al.,

2024; Berahmand et al., 2024]. Neste trabalho, a exploração temporal é realizada através de duas estratégias em conjunto, a separação dos dados em Janelas Deslizantes, e a aplicação do algoritmo *CUSUM*.

2.2 Eventos em Séries Temporais

Eventos em séries temporais correspondem a alterações significativas no padrão de comportamento dos dados ao longo do tempo. Essas alterações podem refletir fenômenos reais com impacto relevante no sistema monitorado, como o início de uma falha em um equipamento, uma mudança de configuração operacional, uma intervenção externa ou qualquer outra modificação que rompa a continuidade estatística da série [Gupta et al., 2022; Yoo et al., 2021]. Tais eventos não são necessariamente instantâneos, pois podem envolver mudanças que se manifestam gradualmente e afetam o regime de geração dos dados de maneira persistente [Li et al., 2024].

A identificação automática desses eventos é uma tarefa essencial em sistemas de monitoramento contínuo, permitindo que decisões sejam tomadas com base em alterações reais do sistema, em vez de flutuações aleatórias ou ruídos. Dentre os tipos de eventos possíveis, destacam-se as anomalias pontuais, que se referem a valores isolados fora do padrão esperado, e os pontos de mudança, que indicam transições estruturais no comportamento da série. Estes últimos são especialmente relevantes em contextos em que o objetivo é detectar quando a dinâmica do sistema sofre uma alteração significativa, ainda que os dados em si não apresentem valores extremos [Li et al., 2024]. Dessa forma, o estudo de eventos em séries temporais fornece a base conceitual para a tarefa de detecção de pontos de mudança, foco deste trabalho.

2.3 Detecção de Pontos de Mudança

Entre os diversos tipos de eventos que podem ocorrer em séries temporais, os pontos de mudança se destacam por representarem transições estruturais significativas no comportamento dos dados. Um ponto de mudança, ou *change point*, ocorre quando há uma alteração abrupta em propriedades estatísticas da série, como a média, a variância, a correlação entre variáveis ou a distribuição dos valores ao longo do tempo [Li et al., 2024]. Tais mudanças indicam que a série entra em um novo regime ou fase, o que pode corresponder, por exemplo, a falhas de equipamentos, alterações operacionais, eventos externos ou mudanças nas condições ambientais.

A detecção de pontos de mudança, conhecida como *CPD*, é a tarefa computacional respon-

sável por identificar automaticamente esses momentos de transição em uma série temporal. Ao contrário de métodos que buscam anomalias pontuais, que se concentram em detectar valores isolados fora do padrão, a *CPD* busca capturar mudanças mais amplas e persistentes na estrutura do sinal, que afetam a dinâmica geral da série [Li et al., 2024].

Tradicionalmente, a *CPD* é abordada por meio de técnicas estatísticas que assumem modelos paramétricos para os dados. Métodos como *CUSUM* e *GLR* são amplamente utilizados nesse contexto, porém exigem conhecimento prévio sobre a distribuição dos dados e apresentam desempenho limitado em séries com comportamento não linear ou altamente ruidoso [Li et al., 2024]. Esses métodos também são sensíveis a flutuações locais, o que pode gerar falsos positivos em contextos práticos.

Nos últimos anos, com o avanço das técnicas de aprendizado de máquina, surgiram abordagens baseadas em modelos de aprendizado profundo capazes de detectar pontos de mudança de forma mais robusta e flexível. Essas abordagens dispensam suposições rígidas sobre a distribuição dos dados e são particularmente eficazes em cenários não supervisionados, nos quais não há rótulos disponíveis indicando os momentos exatos de transição [De Ryck et al., 2021; Cao et al., 2024]. Dentre essas abordagens, destacam-se os autoencoders, que permitem aprender representações compactas do comportamento normal da série e identificar desvios estruturais a partir do erro de reconstrução [Berahmand et al., 2024].

A *CPD*, portanto, pode ser entendida como a tarefa de identificar automaticamente um tipo específico de evento em séries temporais, os pontos de mudança, cuja detecção precoce é fundamental para garantir a estabilidade, segurança e eficiência de sistemas que dependem do monitoramento contínuo de dados [Li et al., 2024; Gupta et al., 2022].

2.4 Aprendizado de Máquina na Detecção de Pontos de Mudança

A detecção de pontos de mudança *CPD* em séries temporais pode ser abordada por diferentes paradigmas, incluindo técnicas estatísticas tradicionais e, mais recentemente, métodos baseados em aprendizado profundo. Tradicionalmente, as abordagens de *CPD* utilizam modelos estatísticos que requerem hipóteses paramétricas rígidas sobre os dados, como os métodos *CUSUM* e *GLR* [De Ryck et al., 2021]. No entanto, essas abordagens apresentam limitações em ambientes com ruído ou comportamento não linear.

Essa transição das abordagens estatísticas para autoencoders é introduzida na Seção 2.3 e explorada em profundidade nas subseções seguintes. Os autoencoders são capazes de aprender

a estrutura “normal” dos dados durante o treinamento, o que os torna aptos a identificar desvios estruturais quando ocorrem mudanças significativas na série. Essa detecção baseia-se no aumento do erro de reconstrução, que serve como sinal indicativo de que a dinâmica da série foi alterada [Berahmand et al., 2024].

2.5 Autoencoders: Arquitetura e Objetivo

Um autoencoder é uma arquitetura de aprendizado não supervisionado cujo objetivo é aprender uma representação compacta dos dados de entrada e, a partir dela, reconstruir os próprios dados. Embora seja comumente implementado por meio de redes neurais artificiais, o conceito de autoencoder refere-se à estrutura funcional de codificação e decodificação dos dados, e não exclusivamente a um tipo específico de rede neural [Berahmand et al., 2024]. A arquitetura fundamental de um autoencoder é composta por duas partes interconectadas, denominadas Encoder e Decoder [Berahmand et al., 2024].

O codificador (*Encoder*) recebe os dados de entrada, x_t (vetor de observações da série temporal X no instante ou janela t), e os mapeia para uma representação de menor dimensão, conhecida como espaço latente, camada oculta (h_t) ou gargalo (*bottleneck*) [De Ryck et al., 2021]. O processo de codificação pode ser formalizado na Equação 2.1 [De Ryck et al., 2021], em que W representa a matriz de pesos (W_e para o *Encoder*), b é o vetor de *bias*, e σ é uma função de ativação não linear. Funções de ativação como *tanh*, ReLU e sigmoid são utilizadas para introduzir não linearidades, permitindo que o modelo capture variações complexas nos dados [De Ryck et al., 2021].

$$h_t = \sigma(Wx_t + b) \quad (2.1)$$

Em seguida, o decodificador (*Decoder*) recebe a representação latente (h_t) e a transforma de volta ao espaço de entrada original, gerando uma saída reconstruída (\hat{x}_t), conforme a Equação 2.2 [De Ryck et al., 2021], em que W' é a matriz de pesos (W_d para o *Decoder*), b' é o vetor de *bias* e σ' é a função de ativação [De Ryck et al., 2021].

$$\hat{x}_t = \sigma'(W'h_t + b') \quad (2.2)$$

O treinamento do autoencoder visa minimizar a diferença entre a entrada original e a saída reconstruída, utilizando uma função de perda (*loss function*). A mais comum é o erro quadrático

de reconstrução, representado pela Equação 2.3 [Berahmand et al., 2024].

$$\mathcal{L}_{\text{rec}} = \sum_t \|x_t - \hat{x}_t\|_2^2 \quad (2.3)$$

2.6 Taxonomia dos Autoencoders

Autoencoders exibem flexibilidade, permitindo personalização para diversos tipos de dados e tarefas por meio do ajuste de sua arquitetura ou funções objetivo [Berahmand et al., 2024]. Ao longo da última década, diversas variantes de autoencoders foram propostas [Berahmand et al., 2024]. A adaptabilidade de sua arquitetura e de suas funções objetivo ressalta sua aplicabilidade a casos específicos, consolidando-os como ferramentas fundamentais para pesquisadores e desenvolvedores de aprendizado de máquina [Berahmand et al., 2024]. O estudo de Berahmand et al. [2024] propõe uma taxonomia abrangente que categoriza os principais e modernos métodos de autoencoders no domínio do aprendizado de máquina em distintas classes. Algumas das arquiteturas incluem autoencoders com regularização, autoencoders robustos, autoencoders geratitivos, autoencoders convolucionais, autoencoders recorrentes, autoencoders semissupervisionados, autoencoders de grafo e autoencoders mascarados.

Essas variantes são detalhadas a seguir. A forma mais simples dessa arquitetura é o *Vanilla Autoencoder (AE)*, introduzido por Rumelhart em 1985 [Berahmand et al., 2024]. Esse modelo é composto por uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída, conforme ilustrado na Figura 1. O codificador mapeia um vetor de entrada X para uma representação latente Z utilizando uma função de codificação f , enquanto o decodificador realiza o mapeamento inverso, transformando Z em uma reconstrução X' dos dados originais por meio de uma função g [Berahmand et al., 2024]. O treinamento busca minimizar o erro de reconstrução L entre X e X' , ajustando os pesos da rede.

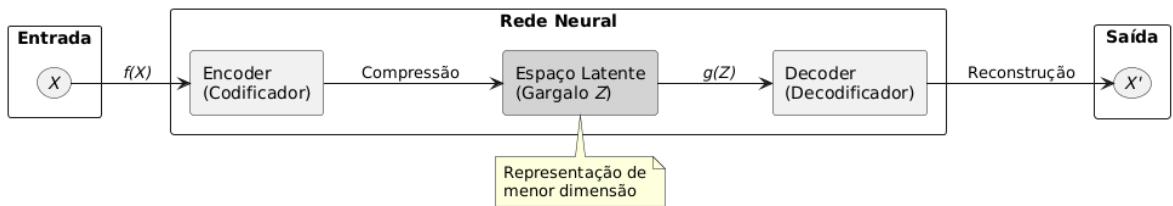


Figura 1: Estrutura de um autoencoder Vanilla, destacando a codificação e a reconstrução a partir do espaço latente.

Com o objetivo de tornar os modelos mais robustos ao ruído presente nos dados reais, foi proposto o *Denoising Autoencoder (DAE)*, que insere ruído artificial durante o treinamento e aprende a reconstruir a versão limpa da entrada [Berahmand et al., 2024]. Isso força o modelo a capturar características relevantes e ignorar variações irrelevantes, promovendo maior generalização em contextos com dados corrompidos.

Para ampliar a profundidade da arquitetura e permitir a extração de representações mais complexas, surgem os *Stacked Autoencoder (SAE)*. Nesse caso, múltiplos autoencoders são empilhados e treinados camada por camada, em que a saída codificada de um *AE* serve como entrada para o próximo [Berahmand et al., 2024]. Essa abordagem permite capturar níveis hierárquicos de abstração dos dados, sendo útil em conjuntos com múltiplas variáveis e padrões latentes complexos.

Outra variação importante é o *Convolutional Autoencoder (CAE)*, que substitui as camadas densas por camadas convolucionais tanto no codificador quanto no decodificador [Berahmand et al., 2024]. Os *CAEs* são eficazes para dados com estrutura espacial, como imagens ou mapas de sensores multivariados, pois capturam dependências locais e padrões espaciais entre os elementos dos dados. Por esse motivo, são amplamente utilizados em tarefas como remoção de ruído (*denoising*), preenchimento de regiões ausentes (*inpainting*), segmentação e super-resolução de imagens.

Por fim, os *Variational Autoencoder (VAE)* introduzem uma abordagem probabilística ao aprendizado das representações latentes. Diferentemente dos autoencoders tradicionais, que aprendem um vetor fixo Z , os *VAEs* aprendem uma distribuição posterior $q(Z|X)$ da qual são extraídas amostras latentes [Berahmand et al., 2024]. Durante a reconstrução, uma amostra Z é obtida dessa distribuição e passada ao decodificador. A função de perda dos *VAEs* inclui um termo de regularização que incentiva essa distribuição a se aproximar de uma Gaussiana padrão, tornando o modelo capaz de gerar novas amostras realistas e modelar a distribuição subjacente dos dados de entrada.

Essas variações arquitetônicas ampliam significativamente as possibilidades de uso dos autoencoders, especialmente em tarefas não supervisionadas como a detecção de pontos de mudança em séries temporais complexas.

Adicionalmente, é relevante distinguir os autoencoders do tipo *forward* daqueles baseados em variações *backward*. Enquanto o primeiro segue o fluxo tradicional de codificação e decodificação, o segundo opera no sentido temporal inverso, reconstruindo os dados do futuro para

o passado. Essa abordagem busca capturar padrões dinâmicos que podem não ser totalmente representados em fluxos unidirecionais. Complementarmente, Liu et al. [2025] demonstra que redes neurais treinadas com séries temporais são capazes de simular detectores estatísticos clássicos, como o *CUSUM*, tanto na direção direta quanto na inversa, reforçando o potencial das arquiteturas reversas na identificação de mudanças estatísticas sutis.

A Tabela 1 apresenta um quadro comparativo sintetizando as principais características e aplicações das arquiteturas descritas anteriormente.

Tabela 1: Comparação entre diferentes tipos de Autoencoders

Tipo	Descrição	Principais Aplicações
Vanilla AE	Estrutura básica com encoder e decoder totalmente conectados. Aprende representações comprimidas dos dados e tenta reconstruí-los.	Redução de dimensionalidade, pré-treinamento de redes, compressão de dados.
Denoising AE (DAE)	Treinado para reconstruir dados limpos a partir de entradas ruidosas. O ruído é adicionado artificialmente no treino.	Remoção de ruído em sinais e imagens, robustez em dados com imperfeições.
Stacked AE (SAE)	Empilha múltiplos autoencoders em camadas profundas para aprender representações mais complexas.	Extração de características profundas, pré-treinamento de redes neurais profundas.
Convolutional AE (CAE)	Utiliza camadas convolucionais em vez de densas, capturando dependências espaciais entre os dados.	Processamento de imagens, vídeo e dados espaciais; super-resolução; segmentação.
Variational AE (VAE)	Modelo gerativo que aprende distribuições probabilísticas no espaço latente, permitindo gerar novos dados.	Geração de imagens, dados sintéticos, aprendizado de representações probabilísticas.

2.7 CUSUM

O método *CUSUM* é uma técnica estatística tradicional e amplamente utilizada para a *CPD* em séries temporais [Ygorra et al., 2024]. Seu funcionamento se baseia na soma acumulada das

diferenças entre os valores da série temporal e sua média.

O algoritmo determina a média de uma série temporal e, em seguida, calcula os resíduos, que são as diferenças entre cada ponto da série e essa média [Ygorra et al., 2024]. A soma desses resíduos é então calculada ao longo do tempo, e um ponto de mudança é considerado detectado quando a soma dos resíduos atinge seu valor máximo, indicando uma alteração persistente na média da série [Ygorra et al., 2024].

Na metodologia específica empregada por Ygorra et al. [2024], para aumentar a confiabilidade da detecção, uma análise de *bootstrap* é realizada para a definição dinâmica de limiares. Essa análise compara a amplitude dos resíduos da série original com a de séries aleatorizadas [Ygorra et al., 2024]. O nível de confiança é definido como a porcentagem de iterações do *bootstrap* em que a amplitude da série original se mantém superior à das séries aleatorizadas. O limiar crítico é um parâmetro definido pelo usuário que estabelece o valor do nível de confiança acima do qual uma mudança é considerada válida. Um limiar crítico mais elevado resulta em menor sensibilidade a mudanças e aleatoriedade, conferindo maior robustez, enquanto um mais baixo é mais sensível a qualquer tipo de alteração [Ygorra et al., 2024].

O *CUSUM* é eficaz na detecção de grandes mudanças na média de séries temporais [Li et al., 2024]. No entanto, geralmente exige conhecimento prévio sobre a distribuição dos dados e apresenta desempenho limitado em séries com comportamento não linear ou altamente ruidoso [Li et al., 2024]. Adicionalmente, pode ser sensível a flutuações locais, o que pode levar a um alto número de falsos positivos em contextos práticos [Li et al., 2024].

2.8 GLR

O *GLR* é outro método estatístico tradicional para a *CPD* [Li et al., 2024]. O *GLR* opera comparando distribuições em janelas adjacentes de dados da série temporal. Esse método busca identificar se a verossimilhança de que os dados em uma janela provêm de uma distribuição é significativamente diferente da verossimilhança de que os dados de uma janela adjacente provêm de outra distribuição, indicando uma mudança [Li et al., 2024]. Assim como o *CUSUM*, ele é utilizado em contextos de *CPD* e apresenta limitações importantes, pois requer a modelagem paramétrica dos dados, o que nem sempre é viável em cenários reais complexos [Li et al., 2024]. Além disso, compartilha desvantagens gerais de métodos estatísticos tradicionais, como a necessidade de suposições rígidas sobre a distribuição dos dados e desempenho restrito em ambientes não lineares ou ruidosos [De Ryck et al., 2021].

2.9 Erro de Reconstrução em Autoencoders

O erro de reconstrução é a principal métrica utilizada em autoencoders para avaliar sua capacidade de aprender representações latentes dos dados. Ele corresponde à diferença entre a entrada original X_t e a saída reconstruída \hat{X}_t [Berahmand et al., 2024; De Ryck et al., 2021]. Formalmente, esse erro pode ser expresso pela Equação 2.4 [Berahmand et al., 2024].

$$E_t = \|X_t - \hat{X}_t\|^2 \quad (2.4)$$

onde E_t representa o erro de reconstrução no instante t , e a norma quadrática é utilizada para medir a discrepância entre os vetores. Alternativamente, podem ser aplicadas outras métricas, como o erro absoluto médio (Mean Absolute Error (MAE)) [Berahmand et al., 2024].

Em tarefas de detecção, valores elevados e persistentes do erro indicam que o autoencoder não conseguiu reconstruir adequadamente os dados, sugerindo desvios em relação ao padrão aprendido. Esse princípio é amplamente empregado em problemas de detecção de anomalias [Gupta et al., 2022; Yoo et al., 2021] e pode ser estendido para a detecção de pontos de mudança, ao considerar não apenas desvios pontuais, mas também alterações estruturais persistentes no erro de reconstrução [De Ryck et al., 2021; Cao et al., 2024]. Para tornar essa análise mais robusta, é comum utilizar o erro acumulado em janelas deslizantes, técnica que suaviza flutuações locais e realça mudanças significativas na dinâmica da série temporal [Cao et al., 2024].

2.10 *Drift* e Aprendizado Adaptativo

Formalmente, o *drift* ocorre quando a relação entre os dados de entrada e a variável alvo se altera entre um instante de tempo e outro, alterando a distribuição conjunta dos dados [Liu et al., 2025]. Isso implica que um modelo treinado com dados coletados no primeiro instante sofre uma degradação de desempenho à medida que o tempo avança e o regime de operação do sistema é alterado, tornando as previsões obsoletas ou imprecisas [Gupta et al., 2022; Liu et al., 2025].

Na literatura, o *drift* é classificado com base na velocidade e na forma como a transição ocorre. Destacam-se dois tipos principais: Mudança Repentina (*Sudden Drift*) e Mudança Gradual (*Gradual Drift*) [Liu et al., 2025].

A mudança repentina ocorre quando o sistema alterna de um estado estável para outro de

forma quase instantânea [Liu et al., 2025]. No caso de monitoramento de poços, um exemplo é o fechamento de uma válvula ou a falha de algum equipamento, o que altera abruptamente a média da pressão monitorada. Esse é o tipo de mudança que algoritmos de detecção baseados em limiares, como o *CUSUM*, são projetados para identificar com maior eficácia [Ygorra et al., 2024].

A mudança gradual ocorre quando o conceito antigo é substituído por um novo de forma lenta e contínua durante um longo período [Liu et al., 2025], podendo decorrer, por exemplo, de desgaste mecânico de sensores ou incrustação de tubulação.

Diante da não estacionariedade, modelos estáticos tornam-se obsoletos, pois a distribuição dos dados evolui com o tempo. Para mitigar esse problema, utiliza-se o Aprendizado Adaptativo, que consiste em atualizar ou substituir o modelo preditivo para que ele reflita o estado atual do sistema [Liu et al., 2025]. Podem ser usadas duas abordagens principais para implementar essa adaptação.

A Adaptação Cega consiste em retreinar o modelo periodicamente, em intervalos fixos, independentemente de ocorrer alguma mudança ou não. Embora seja uma abordagem simples, pode ser computacionalmente custosa e ineficiente se o sistema permanecer estável por longos períodos, desperdiçando recursos de processamento [Gupta et al., 2022].

A Adaptação Informada, por outro lado, aciona o retreinamento ou a atualização de parâmetros apenas quando um detector de mudanças sinaliza que o modelo atual não é mais válido ou que o regime estatístico foi alterado [Gupta et al., 2022; Liu et al., 2025].

A metodologia proposta neste trabalho adota a estratégia de adaptação informada. O sistema opera com um mecanismo de “esquecimento”, no qual, após a confirmação de uma mudança de regime pelo algoritmo *CUSUM*, os dados históricos do regime anterior são descartados, pois passam a atuar como ruído e prejudicam o aprendizado do novo padrão [Ygorra et al., 2024]. Para melhor compreensão desse processo dinâmico, a Figura 2 ilustra os estados de monitoramento e a transição para o retreinamento.

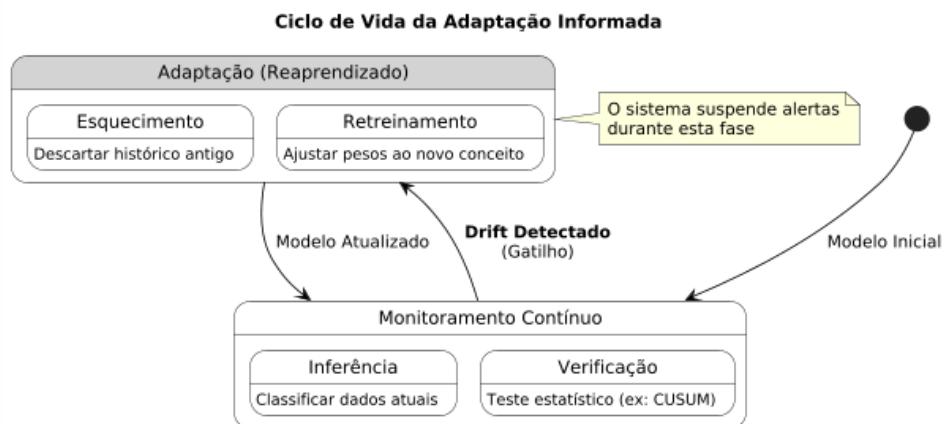


Figura 2: Diagrama de estados representando o conceito de Adaptação Informada, onde o retreinamento é acionado apenas sob demanda.

Com base nos conceitos fundamentais apresentados, torna-se possível analisar como a literatura atual aplica essas técnicas. O capítulo a seguir apresenta uma revisão dos trabalhos relacionados, destacando as abordagens de ponta e identificando as lacunas que este trabalho busca preencher.

Capítulo 3

Trabalhos Relacionados

Este capítulo apresenta uma revisão sistemática da literatura sobre detecção de pontos de mudança utilizando autoencoders. Inicialmente, discute-se o objetivo e o processo de revisão, seguido por um panorama dos métodos atuais. Por fim, são analisadas as lacunas na literatura e apresentadas as contribuições específicas desta pesquisa frente ao estado da arte.

A detecção de pontos de mudança (*CPD*) em séries temporais é uma etapa fundamental na análise de dados e é amplamente aplicada em diversas áreas, como bioinformática, climatologia, processamento de sinais e neurociência [De Ryck et al., 2021; Gupta et al., 2022]. Seu objetivo principal é identificar alterações abruptas nas características ou estatísticas subjacentes dos dados da série temporal, marcando efetivamente os pontos nos quais a série perde sua estacionariedade [Cao et al., 2024; Li et al., 2024].

É importante distinguir a *CPD* da segmentação de séries temporais (*Time Series Segmentation (TSS)*). Enquanto a *TSS* é um método *top-down* que visa dividir dados sequenciais em segmentos menores com base em um número finito de estados do sistema subjacente (frequentemente associada a tarefas de classificação supervisionadas), a *CPD* adota uma abordagem *bottom-up* e foca em identificar os instantes de tempo em que ocorrem as transições [Cao et al., 2024]. O objetivo da *CPD* é detectar mudanças estatísticas súbitas nas variáveis observadas, mesmo quando os segmentos entre pontos consecutivos carecem de interpretação física clara ou rótulos, o que a torna um problema frequentemente tratado como não supervisionado [De Ryck et al., 2021].

Nos últimos anos, houve uma evolução significativa na literatura, com uma transição de abordagens tradicionais baseadas em modelos estatísticos para métodos mais flexíveis e livres de distribuição (*distribution-free*) [Cao et al., 2024; Gupta et al., 2022]. Essas novas abordagens baseadas em aprendizado profundo, como autoencoders, superam a dependência de distribuições estatísticas predefinidas, permitindo a detecção de padrões complexos em dados de alta dimensionalidade [Berahmand et al., 2024; Cao et al., 2024].

3.1 Objetivo da Revisão

Foram selecionados artigos recentes e amplamente citados na literatura técnica sobre *CPD* com autoencoders, priorizando estudos empíricos, aplicações com dados multicanais e abordagens com potencial de generalização em cenários industriais complexos [Gupta et al., 2022; Liu et al., 2025]. A escolha por trabalhos que tratam de correlações cruzadas entre múltiplos canais [Cao et al., 2024] visa alinhar a fundamentação teórica às características do conjunto de dados utilizado neste trabalho. Os estudos incluídos representam o estado da arte na área e foram selecionados com base em sua relevância científica, impacto e contribuição metodológica.

3.2 Processo de Revisão

A seleção dos estudos obedeceu a critérios específicos de inclusão e exclusão. Foram incluídos trabalhos que abordam a detecção de pontos de mudança em séries temporais por meio de técnicas de aprendizado profundo, especialmente autoencoders. Os artigos revisados apresentam resultados experimentais e discutem aplicações práticas em contextos reais. Por outro lado, foram excluídos estudos puramente teóricos, sem validação empírica, bem como aqueles que utilizam exclusivamente métodos estatísticos tradicionais.

A busca principal foi conduzida na base Scopus utilizando a *string*: “time series” and (“autoencoder” or “auto encoder”). Em complemento, aplicou-se a técnica de *snowballing* a partir dos trabalhos de [Gupta et al., 2022] e [De Ryck et al., 2021]. Adicionalmente, para cobrir o contexto específico da aplicação, foi realizada uma consulta direcionada com os termos: “CUSUM” and “Cross”, estendendo a revisão também às referências de [Ygorra et al., 2021] e [Ygorra et al., 2024]. O processo de filtragem e seleção desses artigos está detalhado na Tabela 2.

3.3 Panorama dos Métodos de Detecção de Ponto de Mudança

A literatura de *CPD* divide-se tradicionalmente entre abordagens puramente estatísticas e métodos baseados em aprendizado de máquina. Entre os métodos estatísticos, o *CUSUM* e o *GLR* são os algoritmos mais consolidados. O *CUSUM* destaca-se pela eficiência na detecção de mudanças persistentes e recebeu aprimoramentos recentes importantes, como a estratégia *Cross-T_c*, desenvolvida para validar a coerência das detecções e aumentar a robustez contra

ruídos isolados [Ygorra et al., 2021, 2024]. Já o *GLR* é amplamente utilizado como *baseline* de comparação, operando por meio da razão de verossimilhança entre janelas de dados para identificar alterações nos parâmetros da distribuição, sendo particularmente eficaz quando as premissas estatísticas são atendidas [De Ryck et al., 2021].

Com a crescente complexidade dos dados industriais, métodos baseados em *Deep Learning* tornaram-se necessários para pré-processar séries temporais de alta dimensionalidade. A abordagem padrão consiste em treinar autoencoders para comprimir e reconstruir o comportamento normal dos dados, gerando uma série de erros de reconstrução em que as anomalias se tornam evidentes [Berahmand et al., 2024]. Embora existam arquiteturas especializadas que tentam embutir a detecção na própria rede, como o *Time-Invariant Representation (TIRE)*, que força uma representação invariante no tempo [De Ryck et al., 2021], ou o *Multichannel Temporal Inception Recurrent Encoder (MC-TIRE)*, focado em coerência entre múltiplos canais [Cao et al., 2024], essas soluções frequentemente exigem funções de perda complexas e treinamento específico.

Apesar da sofisticação dessas arquiteturas, uma estratégia eficiente reside na utilização do autoencoder convencional para gerar séries de resíduos, delegando a decisão de mudança para algoritmos estatísticos robustos. Nessa abordagem, o erro de reconstrução atua como um indicador direto de desvio de regime, sobre o qual testes de hipótese podem ser aplicados [Gupta et al., 2022]. A proposta central deste trabalho recai, portanto, sobre a aplicação do *CUSUM* com a estratégia *Cross- T_c* , cuja eficácia será validada em contraposição ao *GLR*. Essa comparação tem o intuito de evidenciar que a estratégia de validação por duplo limiar oferece uma resposta mais adequada às dinâmicas não lineares e aos ruídos do *3W* do que a abordagem baseada estritamente em verossimilhança.

3.4 Análise Crítica e Lacunas na Literatura

Avanços significativos têm sido alcançados na detecção de pontos de mudança (*CPD*), impulsionados pela capacidade das redes neurais de modelar relações não lineares complexas [Li et al., 2024]. Entretanto, a aplicação dessas técnicas em cenários industriais reais enfrenta desafios críticos relacionados à não estacionariedade e ao fenômeno de *concept drift* [Liu et al., 2025]. Muitas arquiteturas de *Deep Learning* assumem que a distribuição dos dados permanece estática, o que raramente ocorre, por exemplo, em poços de petróleo sujeitos a degradação natural e intervenções operacionais [Gupta et al., 2022; Vargas et al., 2019]. Nesses ambientes,

a evolução lenta dos parâmetros do sistema (*drift*) pode ser erroneamente classificada como anomalia por modelos rígidos, gerando altas taxas de falsos positivos e comprometendo a confiabilidade do monitoramento [Liu et al., 2025; De Ryck et al., 2021].

Diante dessas lacunas, este trabalho propõe uma abordagem híbrida que prioriza a robustez da detecção por meio do processamento por janelas deslizantes. Diferentemente de modelos que tentam aprender toda a história da série de uma só vez, a estratégia de segmentação temporal por janelas permite que o autoencoder foque na reconstrução de dependências locais [Gupta et al., 2022]. Essa abordagem, combinada com o rigor estatístico do *CUSUM* aprimorado pela estratégia *Cross- T_c* , busca mitigar os efeitos do *drift*. Enquanto a janela deslizante contextualiza a entrada, o decisor estatístico filtra tendências lentas e isola apenas quebras estruturais abruptas e significativas, garantindo uma distinção precisa entre a evolução natural do processo e falhas críticas.

Ao analisar as abordagens existentes, observa-se que modelos como o *Multichannel Temporal Inception Recurrent Encoder (MC-TIRE)* apresentam excelente desempenho em dados multicanais [Cao et al., 2024], e o *Denoising Autoencoder (DAE)* é eficaz em séries ruidosas [Yoo et al., 2021]. No entanto, essas soluções frequentemente exigem arquiteturas complexas para lidar com a variação temporal. Em contrapartida, métodos baseados em distâncias no espaço latente, como o *Autoencoder-Based Breakpoints Detection (ABD)*, carecem de mecanismos robustos de pós-processamento, tornando-se sensíveis a *outliers* e derivas de longo prazo [De Ryck et al., 2021]. A proposta deste trabalho preenche essa lacuna ao demonstrar que um autoencoder, quando alimentado via janelas deslizantes e acoplado a um decisor estatístico robusto, oferece desempenho competitivo e maior estabilidade em cenários industriais dinâmicos como o do *3W Dataset (3W)*.

3.5 Contribuições do Presente Trabalho

Diante dos desafios impostos pela não estacionariedade e pelo ruído inerente a séries temporais industriais, este trabalho propõe uma abordagem de detecção de anomalias que dissocia a extração de características da decisão estatística. A principal contribuição reside na estruturação de uma metodologia híbrida que integra a capacidade de reconstrução não supervisionada de um autoencoder convencional à estratégia estatística *Cross- T_c* do *CUSUM* [Ygorra et al., 2021]. Diferentemente de métodos que buscam a solução por meio do aumento da complexidade arquitetural da rede neural, esta abordagem privilegia a validação cruzada dos erros de

reconstrução, utilizando o cruzamento de limiares para mitigar falsos positivos sem elevar o custo computacional. Complementarmente, o estudo contribui com uma avaliação empírica rigorosa, contrapondo a eficácia do método proposto ao tradicional teste de razão de verossimilhança (*GLR*) [De Ryck et al., 2021], demonstrando qual estatística oferece maior resiliência a oscilações em dados reais. A validação da metodologia no *3W Dataset* [Vargas et al., 2019] confirma a viabilidade de técnicas *distribution-free* para o monitoramento de transições de regime em sinais complexos, oferecendo uma alternativa estável aos modelos paramétricos.

A fim de embasar o escopo da pesquisa, foi realizada uma busca sistemática na base de dados Scopus. Os parâmetros utilizados para a consulta, bem como a quantidade de trabalhos identificados, estão apresentados na Tabela 2.

Tabela 2: Parâmetros e resultados das estratégias de busca na base Scopus

Parâmetros de Busca		Qtd.
Estratégia 1: Fundamentação (Autoencoder)		
Expressão inicial de busca: “time series” AND (“autoencoder” OR “auto encoder”)		1562
Tipo de material: Artigos de pesquisa revisados por pares		703
Áreas do conhecimento: Ciências Exatas		432
Estratégia 2: Aplicação (CUSUM + CrossTC)		
Expressão inicial de busca: “CUSUM” AND “Cross”		107
Tipo de material: Artigos de pesquisa revisados por pares		92
Filtro: Área de Ciências Exatas		28

A Tabela 3 sintetiza os principais artigos selecionados com base nos critérios definidos, apresentando o ano de publicação, os títulos e as respectivas palavras-chave. Essa organização permite uma visão geral das abordagens recentes aplicadas à detecção de pontos de mudança com autoencoders, além de facilitar a visualização das contribuições mais atuais e reforçar a relevância dos estudos escolhidos para fundamentar a proposta deste trabalho.

Tabela 3: Artigos analisados: detalhamento e métodos comparativos

Ano	Título	Tipo de Dados	Métodos de Comparação
2025	HTM-CDFK: An Online Industrial Control Anomaly Detection Algorithm Based on Hierarchical Time Memory	Multivariado	HTM-CDFK, Detecção de Anomalias
2024	A near-real-time tropical deforestation monitoring algorithm based on the CuSum change detection method	Multivariado	CUSUM, Cross- T_c , Monitoramento de Desmatamento
2024	Autoencoders and their applications in machine learning: a survey	Multivariado	Diferentes arquiteturas de Autoencoders, Redes Neurais
2024	Automatic change-point detection in time series via deep learning	Univariado e Multivariado	Deep Learning, Detecção de Pontos de Mudança
2024	Change Point Detection in Multi-Channel Time Series via a Time-Invariant Representation	Multivariado	Autoencoder, MC-TIRE
2022	Real-time Change-Point Detection: A deep neural network-based adaptive approach for detecting changes in multivariate time series data	Multivariado	Redes Neurais, RSSA, Autoencoder
2021	Change Point Detection in Time Series Data Using Autoencoders with a Time-Invariant Representation	Univariado e Multivariado	Autoencoder, Deep Learning
2021	Monitoring loss of tropical forest cover from Sentinel-1 time-series: A CuSum-based approach	Multivariado	CUSUM, Cross- T_c , Detecção de Mudanças
2021	Prediction of the change points in stock markets using dae-lstm	Univariado	DAE-LSTM, Previsão de pontos de mudança
2019	A realistic and public dataset with rare undesirable real events in oil wells	Multivariado (3W)	Classificação multivariada, Anomalias

A análise dos trabalhos relacionados evidenciou a necessidade de abordagens que lidem melhor com a não estacionariedade sem elevar a complexidade da rede neural. O próximo ca-

pítulo detalha o Método proposto, descrevendo a arquitetura híbrida e a estratégia de validação estatística desenvolvida para endereçar essas questões.

Capítulo 4

Método

A solução desenvolvida neste trabalho estrutura-se como um sistema híbrido de detecção de ponto de mudança em dois estágios, integrando técnicas de controle estatístico de processo com aprendizado profundo não supervisionado¹ apresenta o fluxo geral do método, que se divide em supervisão estatística adaptativa e detecção baseada em reconstrução.

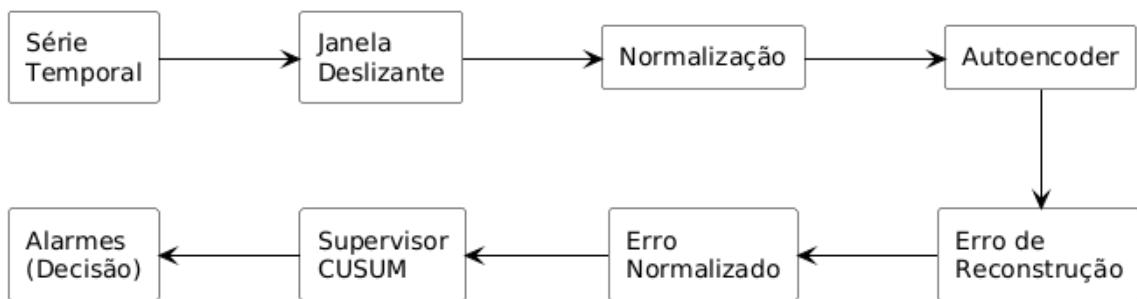


Figura 3: Fluxo geral do método.

Os dados utilizados foram provenientes do 3W Dataset, acessados por meio do *Unified Time Series Event Detection Repository (UniTED)*². O UniTED consiste em um repositório unificado que consolida bases de dados de diversos domínios, submetendo-as a um processo de padronização de formatos e harmonização de anotações para tarefas de detecção de eventos [Lima et al., 2025]. Nesse contexto, foram analisadas duas instâncias distintas do Tipo 1, correspondentes ao Poço 1 (*Well 1*) e ao Poço 2 (*Well 2*), conforme a estruturação disponibilizada pelo repositório [Lima et al., 2025].

Para cada poço, foram avaliadas individualmente sete séries temporais univariadas, correspondentes a sensores físicos distintos do sistema de produção: pressão no fundo do poço (*P-PDG*), pressão na cabeça do poço (*P-TPT*), temperatura na cabeça do poço (*T-TPT*), pressão a montante da choke (*P-MON-CKP*), temperatura a jusante da choke (*T-JUS-CKP*), pressão a jusante da válvula de *gas lift* (*P-JUS-CKGL*) e vazão de gás lift (*QGL*). Essa abordagem permite

¹Disponível em :https://github.com/EIC-BCC/25_2-Deteccao_de_Pontos_de_Mudan-a_em_S-ries_Temporais_Usando_Autoencoders

²Disponível em :<https://github.com/cefet-rj-dal/united> Acessado em: 17/11/2025

avaliar a robustez dos métodos frente a diferentes dinâmicas físicas, níveis de ruído e regimes operacionais, mantendo a coerência experimental entre sensores e poços e alinhando-se a estratégias de representação invariante no tempo para dados multicanais [Cao et al., 2024].

Diferentemente de abordagens tradicionais que utilizam o *CUSUM* apenas para pós-processamento, este trabalho propõe o uso do algoritmo *CUSUM Tabular de Duplo Limiar* como um mecanismo supervisor de estabilidade inspirado em estratégias de monitoramento quase em tempo real [Ygorra et al., 2024]. O supervisor atua em duas frentes. Na primeira, define o início do treinamento: o algoritmo monitora a série desde o começo para identificar o primeiro período de estabilidade estatística. Quando o *CUSUM* detecta a primeira mudança de regime significativa, o corte para o treinamento é definido, garantindo que o modelo aprenda o comportamento normal do processo.

Para mitigar o problema de *drift* e lidar com padrões de sensores em constante mudança [Liu et al., 2025], o algoritmo monitora continuamente a série. Ao confirmar uma mudança de regime operacional (por exemplo, alteração de patamar de pressão pós-intervenção), o *CUSUM* aciona um procedimento de esquecimento e reaprendizado, no qual um novo modelo é treinado com os dados do novo regime estável, uma abordagem adaptativa essencial para séries multivariadas [Gupta et al., 2022].

Durante o período de retreinamento, definido como uma janela de *warmup* de 300 amostras após a detecção do *drift*, o sistema entra em estado de calibração, suspendendo temporariamente os alertas para evitar falsos positivos decorrentes da instabilidade dos pesos da rede neural.

Os parâmetros do *CUSUM* (k e h) são calculados estatisticamente com base na média (μ) e no desvio padrão (σ) da janela de referência, em que o limiar de alerta $h_{low} = 3\sigma$ e o limiar de confirmação $h_{high} = 5\sigma$, seguindo a lógica de detecção baseada em desvios cumulativos aplicada em monitoramento ambiental [Ygorra et al., 2021].

Adaptou-se a estratégia espacial de Ygorra para o domínio temporal. Uma anomalia detectada pelo limiar sensível (h_{low}) só é validada se, dentro de sua janela de duração, houver pelo menos uma ocorrência que supere o limiar rigoroso (h_{high}) [Ygorra et al., 2024].

O núcleo de detecção de anomalias complexas é um Autoencoder *Vanilla*³ implementado via biblioteca *daltoolbox*⁴. A arquitetura consiste em uma rede neural *feedforward* com uma camada de entrada de dimensão w , uma camada oculta (espaço latente) de dimensão $L < w$

³Exemplo de implementação: https://github.com/cefet-rj-dal/daltoolboxdp/blob/main/examples/autoencoder/autoenc_ed.md

⁴Link de acesso: <https://github.com/cefet-rj-dal/daltoolbox>

(para forçar a compressão de características) e uma camada de saída que reconstrói a entrada, conforme a taxonomia padrão de autoencoders para redução de dimensionalidade e extração de características [Berahmand et al., 2024].

O treinamento é realizado por 30 épocas em cada ciclo adaptativo. Durante a fase de monitoramento, o modelo tenta reconstruir os novos dados recebidos. A métrica de anomalia é o Erro Quadrático Médio entre a janela original X_t e a reconstruída \hat{X}_t , técnica consolidada para identificar desvios estruturais [De Ryck et al., 2021], conforme a Equação 4.1 [Gupta et al., 2022].

$$E_t = \frac{1}{w} \sum_{i=1}^w (x_{t,i} - \hat{x}_{t,i})^2 \quad (4.1)$$

A magnitude do erro de reconstrução E_t é sensível à escala da variável monitorada e ao ponto de operação do sistema. Para garantir que o mecanismo de detecção seja robusto e invariante à escala, aplica-se uma etapa de normalização estatística sobre a série de resíduos. O erro normalizado Z_t é calculado por meio da padronização (*z-score*), utilizando as estatísticas obtidas durante o período de referência (conjunto de treino ou *buffer* de adaptação), conforme a Equação 4.2 [Gupta et al., 2022].

$$Z_t = \frac{E_t - \mu_{ref}}{\sigma_{ref}} \quad (4.2)$$

Em que μ_{ref} e σ_{ref} representam, respectivamente, a média e o desvio padrão dos erros de reconstrução calculados durante a fase de *warmup*. Essa transformação converte a série de erros para uma escala de desvios padrão, permitindo que os parâmetros de controle do *CUSUM* (k e h) sejam definidos de forma universal e estatisticamente fundamentada [Ygorra et al., 2021].

Um limiar dinâmico de detecção τ é estabelecido como $\tau = \mu_E + 3\sigma_E$, em que μ_E e σ_E são a média e o desvio padrão dos erros de reconstrução calculados sobre o conjunto de treinamento (zona de normalidade) [Gupta et al., 2022]. Valores de $E_t > \tau$ são classificados como anomalias.

A eficácia do método proposto é avaliada comparando-se as detecções automáticas com os rótulos (*ground truth*) fornecidos por especialistas no 3W Dataset [Vargas et al., 2019]. Devido ao forte desbalanceamento das classes, com predominância de dados normais, a métrica de Acurácia é complementada e confrontada com o F1-Score e a Matriz de Confusão, juntamente com o atraso de detecção. Isso permite uma análise detalhada entre a capacidade de antecipação do modelo, por meio de alertas precoces, e a precisão na localização do evento catalogado [Li

et al., 2024].

Adicionalmente, no contexto de sistemas de monitoramento contínuo, a detecção exata de uma anomalia no milissegundo em que foi rotulada não é estritamente necessária, visto que um alerta gerado com ligeira antecipação ou pequeno atraso em relação ao rótulo manual (*ground truth*) mantém seu valor operacional [Li et al., 2024; De Ryck et al., 2021]. A rigidez de uma avaliação pontual poderia penalizar modelos que, na prática, são eficazes para alertar operadores sobre mudanças iminentes ou recém-ocorridas no processo.

Para refletir essa realidade, utiliza-se o método de Avaliação Suave (*Soft Evaluation*). Define-se uma janela de tolerância temporal δ (neste trabalho, $\delta = 250$ amostras). Uma detecção no instante t_{det} é considerada um Verdadeiro Positivo (VP) se existir um evento real t_{real} que satisfaça a condição de proximidade definida pela Equação 4.3 De Ryck et al. [2021]:

$$|t_{det} - t_{real}| \leq \delta \quad (4.3)$$

Essa abordagem penaliza apenas detecções espúrias distantes de qualquer evento real (Falsos Positivos) ou a ausência completa de detecção na vizinhança do evento (Falsos Negativos), alinhando-se às métricas utilizadas em abordagens recentes de *CPD* baseadas em representações invariantes no tempo [Cao et al., 2024].

Definida a arquitetura do sistema, os parâmetros de treinamento e as métricas de avaliação, o capítulo seguinte apresenta os resultados obtidos. Serão discutidos os dados quantitativos de desempenho e apresentada uma análise qualitativa da atuação do algoritmo frente aos eventos de drift.

Capítulo 5

Resultados

Este capítulo apresenta a avaliação experimental da metodologia proposta para a detecção de anomalias em poços de petróleo, utilizando instâncias do *3W* [Vargas et al., 2019] provenientes do repositório *UniTED* [Lima et al., 2025]. O objetivo é validar a hipótese de que a abordagem híbrida, combinando a supervisão estatística do *CUSUM* com a capacidade de reconstrução de *autoencoders*, oferece robustez superior em cenários sujeitos a não estacionariedade (*concept drift*). A seção inicia-se com a descrição das métricas adotadas, seguida pela análise quantitativa e qualitativa dos resultados obtidos.

5.1 Métricas de Avaliação

Dada a natureza desbalanceada do *3W*, em que períodos de operação normal superam largamente os eventos de anomalia, a acurácia isolada não é uma métrica suficiente. Portanto, a avaliação baseia-se na Matriz de Confusão, que decompõe o desempenho do modelo em quatro categorias distintas: o Verdadeiro Positivo (VP), representando instantes de falha corretamente identificados como anomalia; o Falso Positivo (FP), que denota instantes normais incorretamente classificados como anomalia (alarme falso); o Verdadeiro Negativo (VN), correspondendo a instantes normais corretamente classificados como tais; e o Falso Negativo (FN), indicando instantes de falha que não foram detectados pelo modelo.

A partir desses valores, são calculadas a Precisão (capacidade de não gerar alarmes falsos), a Revocação ou Sensibilidade (capacidade de não perder eventos reais) e o *F1-Score* (média harmônica entre precisão e revocação), conforme as Equações 5.1 [Gupta et al., 2022].

$$\text{Precisão} = \frac{VP}{VP+FP}, \quad \text{Revocação} = \frac{VP}{VP+FN}, \quad F1\text{-Score} = 2 \cdot \frac{\text{Precisão} \cdot \text{Revocação}}{\text{Precisão} + \text{Revocação}} \quad (5.1)$$

Essas métricas são amplamente utilizadas para avaliar algoritmos de detecção de pontos de mudança em séries temporais desbalanceadas, permitindo uma análise equilibrada entre a

sensibilidade e a precisão do modelo [Gupta et al., 2022].

5.2 Resultados Quantitativos

Esta seção apresenta a avaliação comparativa entre o método de referência (*GLR*) e a abordagem proposta (*AE + Cross-T_c*). As Tabelas 4 e 5 sumarizam as métricas de desempenho para os Poços 1 e 2, respectivamente, discriminadas por variável de processo. A análise segmentada permite isolar o impacto da dinâmica de cada sensor na eficácia da detecção [Cao et al., 2024].

Tabela 4: Métricas de detecção discriminadas por sensor para o Poço 1 (Instância do Tipo 1, 3W/UniTED)

Sensor	Método	Precisão	Revocação	F1-Score
P-TPT (Pressão na Cabeça (<i>Topside</i>))	GLR	0.0108	0.9412	0.0214
	AE + Cross-T _c	0.0312	0.0098	0.0149
T-TPT (Temperatura na Cabeça (<i>Topside</i>))	GLR	0.0047	0.5000	0.0093
	AE + Cross-T _c	0.0000	0.0000	0.0000
P-MON-CKP (Pressão a Montante da <i>Choke</i>)	GLR	0.0085	0.9902	0.0168
	AE + Cross-T _c	0.0256	0.0098	0.0142
T-JUS-CKP (Temperatura a Jusante da <i>Choke</i>)	GLR	0.0085	1.0000	0.0169
	AE + Cross-T _c	0.0256	0.0098	0.0142

Tabela 5: Métricas de detecção discriminadas por sensor para o Poço 2 (Instância do Tipo 1, 3W/UniTED)

Sensor	Método	Precisão	Revocação	F1-Score
P-TPT (Pressão na Cabeça (<i>Topside</i>))	GLR	0.0070	0.5000	0.0139
	AE + Cross-T _c	0.0000	0.0000	0.0000
T-TPT (Temperatura na Cabeça (<i>Topside</i>))	GLR	0.0118	1.0000	0.0232
	AE + Cross-T _c	0.0000	0.0000	0.0000
P-MON-CKP (Pressão a Montante da <i>Choke</i>)	GLR	0.0100	1.0000	0.0198
	AE + Cross-T _c	0.0000	0.0000	0.0000
T-JUS-CKP (Temperatura a Jusante da <i>Choke</i>)	GLR	0.0000	0.0000	0.0000
	AE + Cross-T _c	0.0000	0.0000	0.0000

É imperativo contextualizar a magnitude absoluta das métricas apresentadas nas Tabelas 4 e 5. Os valores de precisão e revocação, que podem parecer reduzidos ou próximos de zero

à primeira vista, não indicam ineficácia do modelo, mas refletem o severo desbalanceamento intrínseco ao conjunto de dados 3W. Em séries temporais com mais de 12.000 amostras, onde eventos de anomalia são extremamente raros e curtos (representando, por vezes, menos de 1% dos dados), a prevalência massiva da classe majoritária (normal) faz com que mesmo um pequeno número de falsos positivos penalize severamente a métrica de precisão. Portanto, a avaliação deve focar na capacidade relativa de detecção do evento crítico, e não apenas na pontuação absoluta ponto a ponto.

A análise dos resultados evidencia comportamentos distintos entre os algoritmos. Devido à sua natureza estatística de detecção de mudanças de média, o *GLR* prioriza a revocação, reagindo prontamente a desvios. No entanto, conforme detalhado nas matrizes de confusão (Tabelas 6 e 7), essa característica eleva a ocorrência de Falsos Positivos (*FP*), levando o algoritmo a interpretar ruídos operacionais transitórios como falhas.

Em contraste, o modelo híbrido prioriza a confiabilidade. Observa-se uma redução substancial de alarmes falsos (*FP*), resultando em uma precisão consistentemente superior. O contraponto desta abordagem conservadora, baseada em erro de reconstrução, é um incremento nos Falsos Negativos (*FN*) na avaliação rígida, sugerindo que o modelo pode omitir anomalias sutis ou em estágio inicial.

Tabela 6: Distribuição dos erros de classificação discriminada por sensor para o Poço 1 (Instância do Tipo 1, 3W/*UniTED*)

Sensor	Método	TP	FP	FN	TN
P-TPT (Pressão na Cabeça (<i>Topside</i>))	GLR	96	8773	6	3071
	AE + Cross- T_c	1	31	101	11872
T-TPT (Temperatura na Cabeça (<i>Topside</i>))	GLR	51	10793	51	1051
	AE + Cross- T_c	0	37	102	11866
P-MON-CKP (Pressão a Montante da <i>Choke</i>)	GLR	101	11840	1	4
	AE + Cross- T_c	1	38	101	11865
T-JUS-CKP (Temperatura a Jusante da <i>Choke</i>)	GLR	102	11844	0	0
	AE + Cross- T_c	1	38	101	11865

Tabela 7: Distribuição dos erros de classificação discriminada por sensor para o Poço 2 (Instância do Tipo 1, 3W/UniTED)

Sensor	Método	TP	FP	FN	TN
P-TPT (Pressão na Cabeça (<i>Topside</i>))	GLR	51	7206	51	2884
	AE + Cross- T_c	0	26	102	10123
T-TPT (Temperatura na Cabeça (<i>Topside</i>))	GLR	102	8573	0	1517
	AE + Cross- T_c	0	30	102	10119
P-MON-CKP (Pressão a Montante da <i>Choke</i>)	GLR	102	10077	0	13
	AE + Cross- T_c	0	33	102	10116
T-JUS-CKP (Temperatura a Jusante da <i>Choke</i>)	GLR	0	0	102	10090
	AE + Cross- T_c	0	0	102	10149

Para investigar a natureza dos Falsos Negativos apresentados pelo modelo proposto, realizou-se uma segunda avaliação introduzindo uma tolerância temporal de 250 amostras (*TOL*). A hipótese central é que os *FNs* contabilizados anteriormente não correspondem a falhas de detecção, mas a uma latência de resposta, relacionada ao tempo necessário para que o erro de reconstrução ou o decisor estatístico cruzem seus limiares adaptativos.

As Tabelas 8 e 9 confirmam essa hipótese. Sob o critério de tolerância, o *F1-Score* da abordagem proposta supera o do *GLR* na maioria dos sensores.

Tabela 8: Métricas de detecção com tolerância (250 amostras) discriminadas por sensor para o Poço 1

Sensor	Método	Precisão	Revocação	F1-Score
P-TPT (Pressão na Cabeça (<i>Topside</i>))	GLR	0.0094	1.0000	0.0186
	AE + Cross- T_c	0.0098	1.0000	0.0194
T-TPT (Temperatura na Cabeça (<i>Topside</i>))	GLR	0.0084	1.0000	0.0167
	AE + Cross- T_c	0.0086	1.0000	0.0171
P-MON-CKP (Pressão a Montante da <i>Choke</i>)	GLR	0.0084	1.0000	0.0166
	AE + Cross- T_c	0.0085	1.0000	0.0169
T-JUS-CKP (Temperatura a Jusante da <i>Choke</i>)	GLR	0.0084	1.0000	0.0166
	AE + Cross- T_c	0.0085	1.0000	0.0169

Tabela 9: Métricas de detecção com tolerância (250 amostras) discriminadas por sensor para o Poço 2

Sensor	Método	Precisão	Revocação	F1-Score
P-TPT (Pressão na Cabeça (<i>Topside</i>))	GLR	0.0110	1.0000	0.0218
	AE + Cross- T_c	0.0089	0.7549	0.0176
T-TPT (Temperatura na Cabeça (<i>Topside</i>))	GLR	0.0105	1.0000	0.0209
	AE + Cross- T_c	0.0108	1.0000	0.0214
P-MON-CKP (Pressão a Montante da <i>Choke</i>)	GLR	0.0098	1.0000	0.0193
	AE + Cross- T_c	0.0100	1.0000	0.0198
T-JUS-CKP (Temperatura a Jusante da <i>Choke</i>)	GLR	0.0000	0.0000	0.0000
	AE + Cross- T_c	0.0000	0.0000	0.0000

A validação final deste fenômeno reside na redistribuição dos erros, apresentada nas Tabelas 10 e 11. Verifica-se uma migração expressiva de ocorrências da coluna de Falsos Negativos (*FN*) para Verdadeiros Positivos (*TP*) no método híbrido, enquanto a taxa de Falsos Positivos permanece baixa e estável. Isso demonstra que a abordagem *AE + Cross- T_c* é capaz de detectar a integralidade dos eventos anômalos, sujeita apenas a uma latência operacionalmente aceitável em prol de um diagnóstico robusto e livre de alarmes falsos. Essa análise com tolerância temporal alinha-se a estudos recentes que utilizam métricas flexíveis para avaliar a eficácia de algoritmos de detecção de mudanças em cenários complexos [De Ryck et al., 2021; Li et al., 2024].

Tabela 10: Distribuição dos erros de classificação com tolerância (250 amostras) para o Poço 1

Sensor	Método	TP	FP	FN	TN
P-TPT (Pressão na Cabeça (<i>Topside</i>))	GLR	102	10767	0	1636
	AE + Cross- T_c	102	10330	0	2073
T-TPT (Temperatura na Cabeça (<i>Topside</i>))	GLR	102	11998	0	405
	AE + Cross- T_c	102	11704	0	699
P-MON-CKP (Pressão a Montante da <i>Choke</i>)	GLR	102	12094	0	309
	AE + Cross- T_c	102	11853	0	550
T-JUS-CKP (Temperatura a Jusante da <i>Choke</i>)	GLR	102	12094	0	309
	AE + Cross- T_c	102	11853	0	550

Tabela 11: Distribuição dos erros de classificação com tolerância (250 amostras) para o Poço 2

Sensor	Método	TP	FP	FN	TN
P-TPT (Pressão na Cabeça (<i>Topside</i>))	GLR	102	9156	0	1493
	AE + Cross- T_c	77	8549	25	2100
T-TPT (Temperatura na Cabeça (<i>Topside</i>))	GLR	102	9575	0	1074
	AE + Cross- T_c	102	9328	0	1321
P-MON-CKP (Pressão a Montante da <i>Choke</i>)	GLR	102	10340	0	309
	AE + Cross- T_c	102	10098	0	551
T-JUS-CKP (Temperatura a Jusante da <i>Choke</i>)	GLR	0	0	102	10649
	AE + Cross- T_c	0	0	102	10649

Ao contrastar estes resultados com a literatura revisada, observa-se que a abordagem proposta atinge robustez operacional sem recorrer à complexidade arquitetural excessiva observada em modelos como o *MC-TIRE* [Cao et al., 2024] ou arquiteturas profundas de representação invariante [De Ryck et al., 2021]. Enquanto trabalhos correlatos buscam mitigar o ruído aumentando a profundidade da rede neural, os dados aqui apresentados demonstram que a delegação da decisão de mudança para um componente estatístico robusto (*CUSUM* com $Cross-T_c$) oferece uma estabilidade equiparável. Isso valida a hipótese de que modelos híbridos, computacionalmente mais leves, são alternativas viáveis e competitivas para a detecção de anomalias em ambientes industriais reais.

5.3 Análise Visual e Qualitativa

Nesta seção, analisa-se o comportamento do modelo em cenários específicos para demonstrar a atuação do mecanismo de adaptação ao *drift* e a qualidade dos resíduos gerados.

Inicialmente, avalia-se a capacidade de detecção de mudanças de regime e o consequente reaprendizado do modelo. A Figura 4 ilustra uma instância do Tipo 1 em que ocorre uma alteração significativa no comportamento da série temporal antes do evento de falha.

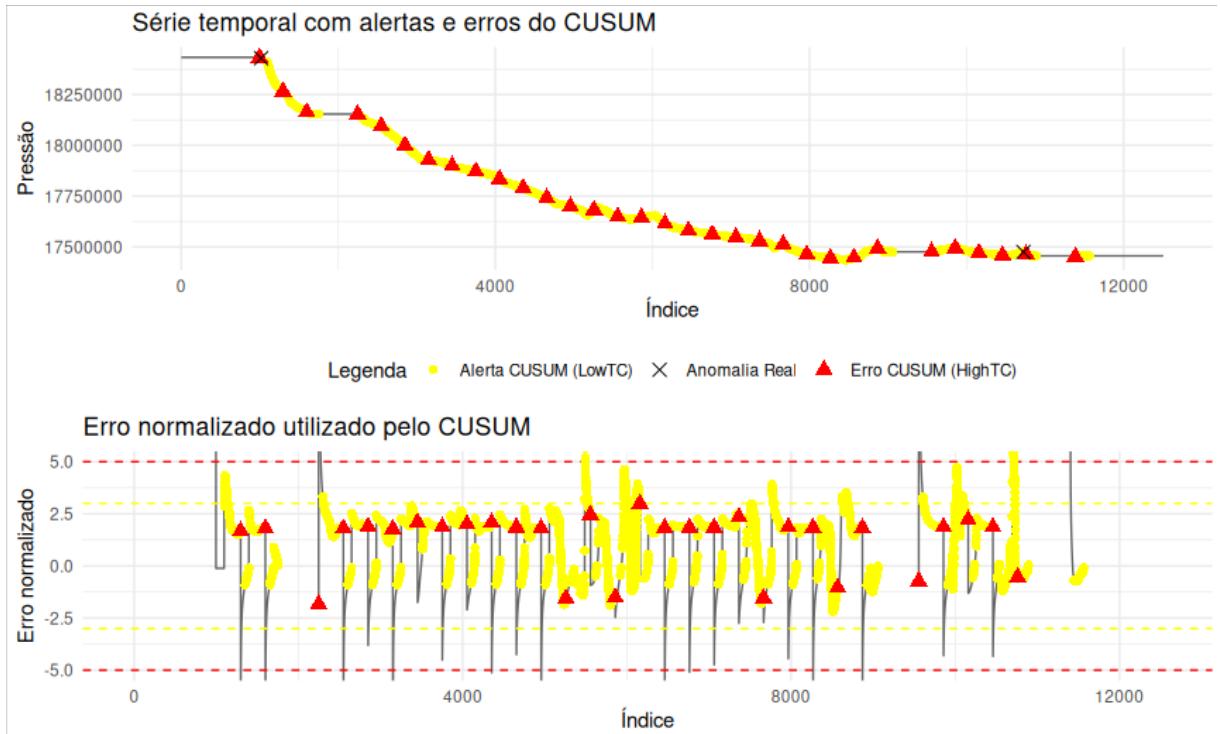


Figura 4: Adaptação do método proposto (AE + *CUSUM*) a um evento de *concept drift*.

A Figura 4 ilustra a eficácia da abordagem em um cenário de não estacionariedade. Observa-se que, nas imediações do instante $t \approx 996$, a variável monitorada sofre um deslocamento significativo de média (*mean shift*), alterando o perfil estatístico da série.

Em uma abordagem estática tradicional, tal mudança resultaria em um aumento persistente do erro de reconstrução, pois o modelo tentaria validar os novos dados com base em uma distribuição obsoleta, gerando Falsos Positivos contínuos. No entanto, o algoritmo proposto demonstra robustez: o supervisor *CUSUM* detecta a quebra de estabilidade estatística e aciona o gatilho de retreinamento [Liu et al., 2025]. Como resultado, o *AE* ajusta seus pesos ao novo padrão de dados, mantendo o resíduo abaixo do limiar τ . Isso assegura que, quando a anomalia real ocorre posteriormente (em $t \approx 1017$), o sistema mantenha a sensibilidade necessária para detectá-la corretamente, sem ter sido saturado por alarmes espúrios anteriores.

Ressalta-se que, durante a fase de retreinamento (período de *warmup* do novo modelo), o sistema opera em modo de calibração, suspendendo a emissão de alertas. Esse hiato de monitoramento é uma limitação intrínseca da abordagem de adaptação informada, necessária para garantir que os novos parâmetros do autoencoder estabilizem antes de retomar a inferência.

A consequência direta da estratégia de adaptação torna-se evidente ao analisar o comportamento dos detectores após a mudança de regime. A Figura 5 exibe a resposta do modelo *GLR*

durante o período de operação estável.

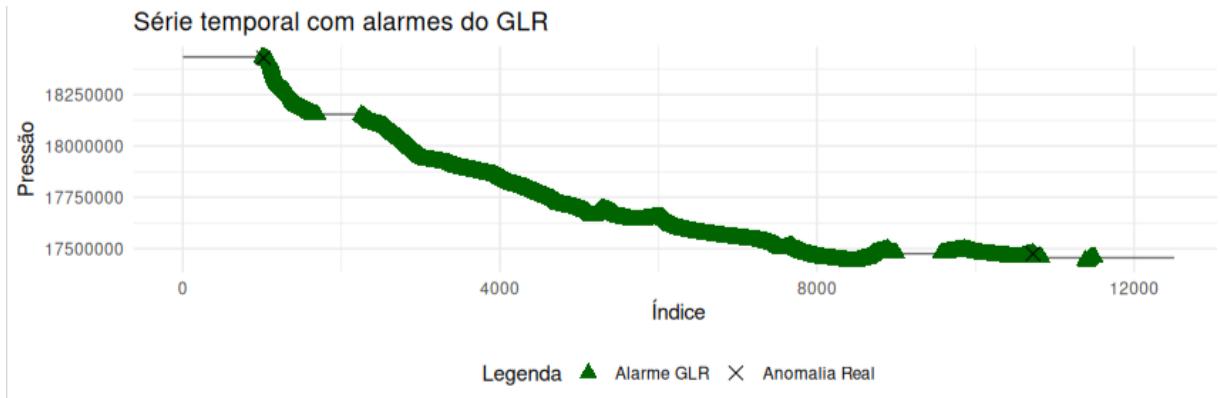


Figura 5: Resposta do algoritmo *GLR* ao mesmo evento de *concept drift*.

A limitação da abordagem estática é evidenciada na Figura 5. Observa-se que o algoritmo *GLR*, calibrado para os parâmetros do regime inicial, interpreta o deslocamento do nível de pressão não como uma nova condição normal, mas como uma anomalia persistente de alta magnitude [Ygorra et al., 2024].

Consequentemente, a estatística de monitoramento permanece saturada acima do limiar de decisão por todo o período subsequente. Esse comportamento resulta na geração massiva e contínua de Falsos Positivos, o que, na prática, inviabiliza a operação autônoma do sistema de monitoramento devido ao excesso de alarmes.

Nesse contexto, é fundamental ressaltar que a implementação do *GLR* adotada neste estudo segue, propositalmente, uma abordagem canônica e estática, parametrizada apenas com os dados iniciais. Essa escolha experimental é deliberada para isolar e quantificar o impacto da não estacionariedade (*concept drift*) sobre modelos de decisão fixos. A degradação acentuada do desempenho observada não reflete necessariamente uma incapacidade matemática do algoritmo, mas a limitação inerente de estratégias que não incorporam mecanismos de "esquecimento e reaprendizado". Portanto, a comparação evidencia que, em cenários industriais dinâmicos, a estratégia de adaptação é um fator determinante para a robustez, sobrepondo-se à escolha isolada do algoritmo de detecção.

5.4 Ameaças à Validade

Embora os resultados sejam promissores, algumas limitações devem ser consideradas. Primeiramente, destaca-se a questão da generalização do método, dado que a validação experimental restringe-se às instâncias dos Poços 1 e 2 do conjunto Tipo 1 [Lima et al., 2025]. Como

essas instâncias são caracterizadas majoritariamente por eventos pontuais, a eficácia da abordagem em anomalias com dinâmicas de evolução lenta (*incipient faults*), como a incrustação progressiva ao longo de meses, ainda carece de investigação empírica adicional [Liu et al., 2025; Gupta et al., 2022].

Outra limitação teórica reside na natureza estatística do erro de reconstrução. Por ser baseado no erro quadrático, o comportamento dos resíduos tende a seguir uma distribuição Qui-quadrado (χ^2), violando a premissa de normalidade estrita assumida pelo algoritmo *CUSUM* clássico [Ygorra et al., 2024]. Embora a normalização via Z-score mitigue disparidades de escala [Gupta et al., 2022], a assimetria inerente à distribuição dos erros pode impactar a precisão dos limiares probabilísticos calculados, favorecendo abordagens livres de distribuição em trabalhos futuros [Li et al., 2024; De Ryck et al., 2021].

Por fim, observa-se uma dependência crítica de hiperparâmetros, especificamente no limiar de detecção do *CUSUM* (h_{high}). Uma calibração inadequada desse parâmetro pode resultar em retrainamentos excessivos (instabilidade) ou em perda de sensibilidade (falsos negativos), exigindo conhecimento específico do domínio para o ajuste fino [Ygorra et al., 2021; Cao et al., 2024].

Em suma, os experimentos demonstraram que a abordagem proposta oferece um equilíbrio superior entre sensibilidade e robustez em comparação ao método estático. O próximo capítulo apresenta a Conclusão do trabalho, retomando os objetivos iniciais e sugerindo direções para pesquisas futuras.

Capítulo 6

Conclusão

Este trabalho aborda o desafio da detecção de pontos de mudança e anomalias em séries temporais multivariadas no contexto da indústria de óleo e gás, utilizando o 3W. O problema central investigado é a obsolescência de modelos preditivos estáticos em ambientes não estacionários, em que fenômenos de *concept drift*, causados por degradação natural ou intervenções operacionais, elevam substancialmente a taxa de falsos positivos em sistemas de monitoramento tradicionais.

A hipótese principal da pesquisa estipula que a combinação de um autoencoder não supervisionado (para extração de características não lineares) com um supervisor estatístico *CUSUM* (para controle de estabilidade e decisão) resulta em um sistema mais robusto do que o uso isolado de técnicas clássicas ou puramente neurais. Os resultados experimentais obtidos corroboraram essa hipótese. A estratégia híbrida proposta demonstra capacidade superior de adaptação, utilizando a sensibilidade do *CUSUM* para identificar quebras de regime e acionar o mecanismo de reaprendizado ("adaptação informada"), mantendo o erro de reconstrução do autoencoder controlado nas novas condições operacionais.

Em relação aos objetivos específicos, o trabalho cumpre sua proposta ao implementar e avaliar o *Vanilla Autoencoder* (*AE*) integrado à lógica de janelas deslizantes. A comparação quantitativa com o método *GLR* evidencia que, embora o *GLR* seja matematicamente rigoroso, sua aplicação na forma estática o torna vulnerável a derivas de processo. O estudo demonstra que a superioridade do método proposto reside, primariamente, na sua capacidade adaptativa de redefinir a normalidade, sugerindo que mesmo métodos estatísticos clássicos podem beneficiar-se da mesma lógica de janelas deslizantes e retreinamento implementada aqui no contexto de redes neurais.

As contribuições deste estudo consolidam-se, inicialmente, na estruturação de uma arquitetura híbrida que dissocia a representação do dado, realizada pela rede neural, da decisão de mudança, conduzida pela estatística, conferindo maior interpretabilidade ao modelo. Complementarmente, demonstra-se a eficácia prática da estratégia de "esquecimento e reaprendizado" guiada por limiares dinâmicos, a qual mitiga o problema de *drift* sem a necessidade de

intervenção manual constante. O trabalho valida, ainda, o uso da estratégia de cruzamento de limiares (*Cross-T_c*) no contexto de sensores industriais, comprovando sua utilidade para filtrar oscilações de curto prazo e assegurar a persistência das anomalias detectadas.

Como sugestões para trabalhos futuros e aprofundamento da pesquisa, recomenda-se a investigação de arquiteturas recorrentes, substituindo o Autoencoder *Vanilla* por modelos LSTM ou Transformers para capturar dependências temporais de longo prazo, o que pode melhorar a detecção em dinâmicas de falha mais lentas e complexas. Outra linha promissora envolve o aprendizado contínuo (*Continual Learning*), explorando técnicas que permitam a atualização dos pesos da rede neural sem o descarte total do conhecimento anterior, visando maior eficiência computacional e plasticidade do modelo. Sugere-se também o estudo de abordagens semissupervisionadas, investigando métodos que possam aproveitar a pequena quantidade de rótulos disponíveis para guiar o aprendizado do espaço latente e refinar a fronteira de decisão entre o normal e o anômalo. Finalmente, indica-se a validação em outros domínios, aplicando a metodologia proposta em diferentes conjuntos de dados industriais ou ambientais para verificar a generalização da estratégia de combate ao *drift*.

Conclui-se, portanto, que a integração entre o rigor da estatística clássica e a flexibilidade do aprendizado profundo representa um caminho maduro e viável para o desenvolvimento de sistemas de monitoramento industrial inteligentes e resilientes.

Referências

- Berahmand, K., Daneshfar, F., Salehi, E. S., Li, Y., and Xu, Y. Autoencoders and their applications in machine learning: a survey. *Artificial Intelligence Review*, 57(2):28, 2024. <https://doi.org/10.1007/s10462-023-10662-6>
- Cao, Z., Seeuws, N., De Vos, M., and Bertrand, A. Change Point Detection in Multi-Channel Time Series via a Time-Invariant Representation. *IEEE Transactions on Knowledge and Data Engineering*, 36(12):7743 – 7756, 2024. <https://doi.org/10.1109/TKDE.2023.3347356>
- De Ryck, T., De Vos, M., and Bertrand, A. Change Point Detection in Time Series Data Using Autoencoders with a Time-Invariant Representation. *IEEE Transactions on Signal Processing*, 69:3513 – 3524, 2021. <https://doi.org/10.1109/TSP.2021.3087031>
- Gupta, M., Wadhvani, R., and Rasool, A. Real-time Change-Point Detection: A deep neural network-based adaptive approach for detecting changes in multivariate time series data. *Expert Systems with Applications*, 209:118260, 2022. <https://doi.org/10.1016/j.eswa.2022.118260>
- Li, J., Fearnhead, P., Fryzlewicz, P., and Wang, T. Automatic change-point detection in time series via deep learning. *Journal of the Royal Statistical Society Series B: Statistical Methodology*, 86(2):273–285, 2024. <https://doi.org/10.1093/rsssb/qkae004>
- Lima, J., Castro, H., Oliveira, L., Paixão, E., Baroni, L., Salles, R., Vargas, R., and Ogasawara, E. United: A unified time series event detection repository. In *Anais do XIX Brazilian e-Science Workshop*, pages 1–8, Porto Alegre, RS, Brasil. SBC, 2025. <https://doi.org/10.5753/bresci.2025.247972>
- Liu, J., Zhang, Y., Wang, Z., Ren, Y., Chen, L., and Chen, Y. HTM-CDFK: An Online Industrial Control Anomaly Detection Algorithm Based on Hierarchical Time Memory. *IEEE Transactions on Dependable and Secure Computing*, 22(06):5821–5836, 2025. <https://doi.org/10.1109/TDSC.2025.3549741>
- Vargas, R. E. V., Munaro, C. J., Ciarelli, P. M., Medeiros, A. G., Amaral, B. G. d., Barrionuevo, D. C., Araújo, J. C. D. d., Ribeiro, J. L., and Magalhães, L. P. A realistic and public dataset

with rare undesirable real events in oil wells. *Journal of Petroleum Science and Engineering*, 181:106223, 2019. <https://doi.org/10.1016/j.petrol.2019.106223>

Ygorra, B., Frappart, F., Wigneron, J.-P., Catry, T., Pillot, B., Pfefer, A., Courtalon, J., and Riazanoff, S. A near-real-time tropical deforestation monitoring algorithm based on the CuSum change detection method. *Frontiers in Remote Sensing*, 5, 2024. <https://doi.org/10.3389/frsen.2024.1416550>

Ygorra, B., Frappart, F., Wigneron, J. P., Moisy, C., Catry, T., Baup, F., Hamunyela, E., and Riazanoff, S. Monitoring loss of tropical forest cover from Sentinel-1 time-series: A CuSum-based approach. *International Journal of Applied Earth Observation and Geoinformation*, 103:102532, 2021. <https://doi.org/10.1016/j.jag.2021.102532>

Yoo, S., Jeon, S., Jeong, S., Lee, H., Ryou, H., Park, T., Choi, Y., and Oh, K. Prediction of the change points in stock markets using dae-lstm. *Sustainability (Switzerland)*, 13(21), 2021. <https://doi.org/10.3390/su132111822>